

Incerteza

Capítulo 13 – Russell & Norvig

Seções 13.1 a 13.4

Incerteza

- Seja a ação A_t = sair para o aeroporto t minutos antes do voo.
- A_t me levará ao aeroporto a tempo?
- Dificuldades de saber o resultado da ação:
 - Estados parcialmente observáveis
 - Estados das estradas, trânsito, etc.
 - Sensores ruidosos
 - Relatórios de trânsito
 - Incerteza quanto ao efeito das ações
 - Acidentes, pneu furado, etc.
 - Grande complexidade em prever e modelar o trânsito

Incerteza

- Um procedimento puramente lógico não é muito útil nesse caso, porque:
 1. Arriscaria deduzir algo potencialmente falso
 - “ A_{45} me levará a tempo ao aeroporto”
 2. Levaria a conclusões fracas para tomada de decisões
 - “ A_{45} me levará a tempo ao aeroporto, se nenhum acidente ocorrer na ponte, se não chover, se nenhum pneu furar, etc.”
 3. Levaria a conclusões que não práticas
 1. “ A_{1440} me levará a tempo ao aeroporto”

Lidando com a incerteza

- Probabilidade
 - Modela o **grau de crença** de um agente dadas as evidências disponíveis
 - “ A_{25} chegará a tempo com probabilidade 0.04”
 - “ A_{45} chegará a tempo com probabilidade 0.85”
 - “ A_{60} chegará a tempo com probabilidade 0.95”

Probabilidade

- A probabilidade proporciona um meio para resumir a incerteza que vem de:
 - Preguiça = falha em enumerar todas as possíveis exceções à regra
 - Ignorância = falta de conhecimento sobre fatos relevantes, condições iniciais

Probabilidade

- Probabilidade subjetiva ou bayesiana
 - Estabelece o estado de crença do agente em uma sentenças, dadas as evidências.
 - Muda quando novas evidências chegam
 - $P(A_{25} | \text{nenhum acidente}) = 0.06$
 - $P(A_{25} | \text{nenhum acidente, 5 a.m.}) = 0.15$
- As sentenças são verdadeiras ou falsas.
 - O que muda é o grau de crença do agente na sentença.
 - Atribuir probabilidade 0 a uma sentença significa acreditar que ela é falsa com certeza absoluta.
 - Atribuir probabilidade 1 a uma sentença significa acreditar que ela é verdadeira com certeza absoluta.

Decisões sob incerteza

- Suponha o seguinte conjunto de crenças:

$P(A_{25} \text{ chega a tempo} \mid \dots)$	$= 0.04$
$P(A_{90} \text{ chega a tempo} \mid \dots)$	$= 0.70$
$P(A_{120} \text{ chega a tempo} \mid \dots)$	$= 0.95$
$P(A_{1440} \text{ chega a tempo} \mid \dots)$	$= 0.9999$

- Que ação o agente deve tomar?
 - Depende de suas **preferências** sob perder o voo versus o tempo esperando no aeroporto.
 - Teoria da utilidade = representação de preferências
 - Teoria da decisão = teoria da probabilidade + teoria da utilidade

Introdução à probabilidade

- Elemento básico: variável aleatória
 - Análogo à lógica proposicional
 - Mundos possíveis são definidos pela atribuição de valores às variáveis.
 - Cada variável aleatória tem um **domínio** que determina seus valores possíveis.
 - Tipos de domínio
 - **Booleano**, ex.: *Cárie* possui valores em <verdadeiro,falso>
 - **Discreto**, ex.: *Clima* possui valores em <ensolarado, chuvoso, nublado, neve>
 - **Contínuo**, ex.: *Temperatura*

Introdução à probabilidade

- Proposições elementares
 - São construídas através da atribuição de valores a variáveis.
 - Ex.: *Clima* = ensolarado, *Cárie* = falso (abreviado como $\neg \text{cárie}$)
- Proposições complexas
 - São formadas a partir de proposições elementares e conectivos lógicos padrão
 - Ex.: *Clima* = ensolarado \vee *Cárie* = falso

Introdução à probabilidade


- Evento atômico
 - Especificação completa do estado do mundo sobre o qual o agente está incerto.
 - Uma atribuição de valores a TODAS as variáveis das quais o mundo é formado.
 - Eventos atômicos são mutuamente exclusivos e exaustivos.

Evento atômico: exemplo

- Se o mundo consistir somente de 2 variáveis booleanas (*Cárie* e *DorDeDente*), então há 4 eventos atômicos distintos:
 - *Cárie* = verdadeiro \wedge *DorDeDente* = verdadeiro
 - *Cárie* = verdadeiro \wedge *DorDeDente* = falso
 - *Cárie* = falso \wedge *DorDeDente* = verdadeiro
 - *Cárie* = falso \wedge *DorDeDente* = falso

Axiomas da Probabilidade

- Para quaisquer proposições A, B
 - $0 \leq P(A) \leq 1$
 - $P(\text{verdade}) = 1$ e $P(\text{falso}) = 0$
 - (proposições neces. verdadeiras -- válidas -- prob=1 e proposições neces. falsas – não satisfatíveis -- prob.=0)
 - $P(A \vee B) = P(A) + P(B) - P(A \wedge B)$



Probabilidade

- A probabilidade de uma proposição é igual à soma das probabilidades dos eventos atômicos em que ela é válida:

$$P(a) = \sum_{e_i \in e(a)} P(e_i)$$

- Essa equação permite calcular a probabilidade de qualquer proposição dada uma distribuição conjunta total que especifique todos os eventos atômicos.

Probabilidade incondicional ou “a priori”

- É o grau de crença em uma proposição na ausência de outras informações.
 - Exemplos:
 - $P(\text{Cárie} = \text{verdadeiro}) = 0.1$
 - $P(\text{Clima} = \text{ensolarado}) = 0.72$
 - Distribuição de probabilidades
 - Dá probabilidades a todos os valores possíveis de uma variável aleatória.
- $P(\text{Clima}) = \langle 0.72, 0.1, 0.08, 0.1 \rangle$ (**normalizado**, i.e., soma da 1)

Distribuição de Probabilidade Conjunta

- Probabilidades de todas as combinações de valores de um conjunto de variáveis aleatórias.

$P(\text{Clima}, \text{Carie})$ = tabela 4×2 de valores:

<i>Clima =</i>	ensolarado	chuvoso	nublado	neve
<i>Cárie = verdadeiro</i>	0.144	0.02	0.016	0.02
<i>Cárie = falso</i>	0.576	0.08	0.064	0.08

- Uma distribuição conjunta total especifica a probabilidade de qualquer evento atômico.
 - Qualquer probabilidade nesse domínio pode ser calculada a partir da distribuição conjunta total.

Probabilidade condicional ou “a posteriori”

- É o grau de crença em uma proposição dada a presença de evidências (valores de variáveis aleatórias conhecidos).
 - Exemplos:
 - $P(\text{Cárie} = \text{verdadeiro} \mid \text{DorDeDente} = \text{verdadeiro}) = 0.8$
 - $P(\text{Cárie} = \text{verdadeiro} \mid \text{DorDeDente} = \text{verdadeiro}, \text{Cárie} = \text{verdadeiro}) = 1$
 - $P(\text{Cárie} = \text{verdadeiro} \mid \text{DorDeDente} = \text{verdadeiro}, \text{Ensolarado} = \text{verdadeiro}) = P(\text{Cárie} = \text{verdadeiro} \mid \text{DorDeDente}) = 0.8$
- Distribuição condicional
 - $P(Y|X)$ fornece o valor de $P(Y=y_i \mid X=x_j)$ para cada valor de i e j possíveis.

Probabilidade Condicional

- Pode ser definida em termos de probabilidades a priori:
 $P(a \mid b) = P(a \wedge b) / P(b)$ se $P(b) > 0$
- **Regra do produto** dá uma definição alternativa:
 $P(a \wedge b) = P(a \mid b) P(b) = P(b \mid a) P(a)$
- Isso pode ser generalizado para distribuições totais: e.g.
 $\mathbf{P}(\text{Clima}, \text{Cárie}) = \mathbf{P}(\text{Clima} \mid \text{Cárie}) \mathbf{P}(\text{Cárie})$
(que é um conjunto de 4×2 equações, **não** uma multiplicação matricial.)
- **Regra da cadeia** é obtida a partir de aplicações sucessivas da regra do produto:
$$\begin{aligned} P(X_1, \dots, X_n) &= P(X_1, \dots, X_{n-1}) P(X_n \mid X_1, \dots, X_{n-1}) \\ &= P(X_1, \dots, X_{n-2}) P(X_{n-1} \mid X_1, \dots, X_{n-2}) P(X_n \mid X_1, \dots, X_{n-1}) \\ &= \dots \\ &= \prod_{i=1}^n P(X_i \mid X_1, \dots, X_{i-1}) \end{aligned}$$

Inferência Probabilística

- **Inferência probabilística**: a computação a partir de evidências observadas de probabilidades posteriores para proposições de consulta.
- **Inferência com o uso de distribuições conjuntas totais**: base de conhecimento a partir da qual são derivadas respostas para todas as consultas.

Exemplo:

Inferência Probabilística

- Suponha um domínio com a seguinte distribuição conjunta total:

	<i>dordedente</i>		\neg <i>dordedente</i>	
	<i>boticão</i>	\neg <i>boticão</i>	<i>boticão</i>	\neg <i>boticão</i>
<i>cárie</i>	.108	.012	.072	.008
\neg <i>cárie</i>	.016	.064	.144	.576

- Para qualquer proposição α , $P(\alpha)$ é a soma dos eventos atômicos w onde α ocorre: $P(\alpha) = \sum_{w:w|\models \alpha} P(w)$

Exemplo:

Inferência Probabilística

- Suponha um domínio com a seguinte distribuição conjunta total:

	<i>dordedente</i>		\neg <i>dordedente</i>	
	<i>boticão</i>	\neg <i>boticão</i>	<i>boticão</i>	\neg <i>boticão</i>
<i>cárie</i>	.108	.012	.072	.008
\neg <i>cárie</i>	.016	.064	.144	.576

- Para qualquer proposição ***a***, $P(a)$ é a soma dos eventos atômicos ***w*** onde ***a*** ocorre: $P(a) = \sum_{w:w|=a} P(w)$

$$P(\textit{dordedente}) = 0.108 + 0.012 + 0.016 + 0.064 = 0.2$$

Exemplo:

Inferência Probabilística

- Suponha um domínio com a seguinte distribuição conjunta total:

	<i>dordedente</i>		\neg <i>dordedente</i>	
	<i>boticão</i>	\neg <i>boticão</i>	<i>boticão</i>	\neg <i>boticão</i>
<i>cárie</i>	.108	.012	.072	.008
\neg <i>cárie</i>	.016	.064	.144	.576

- Para qualquer proposição \mathbf{a} , $P(\mathbf{a})$ é a soma dos eventos atômicos \mathbf{w} onde \mathbf{a} ocorre: $P(\mathbf{a}) = \sum_{\mathbf{w}: \mathbf{w}|=\mathbf{a}} P(\mathbf{w})$

$$P(\textit{dordedente} \vee \textit{cárie}) = 0.108 + 0.012 + 0.016 + 0.064 + 0.072 + 0.008 = 0.28$$

Exemplo:

Inferência Probabilística

- Podemos calcular probabilidades condicionais:

	<i>dordedente</i>		\neg <i>dordedente</i>	
	<i>boticão</i>	\neg <i>boticão</i>	<i>boticão</i>	\neg <i>boticão</i>
<i>cárie</i>	.108	.012	.072	.008
\neg <i>cárie</i>	.016	.064	.144	.576

$$\begin{aligned}
 P(\neg \text{cárie} | \text{dordedente}) &= \frac{P(\neg \text{cárie} \wedge \text{dordedente})}{P(\text{dordedente})} \\
 &= \frac{0.016 + 0.064}{0.108 + 0.012 + 0.016 + 0.064} \\
 &= 0.4
 \end{aligned}$$

Normalização

	<i>dordedente</i>		<i>¬dordedente</i>	
	<i>boticão</i>	<i>¬boticão</i>	<i>boticão</i>	<i>¬boticão</i>
<i>cárie</i>	.108	.012	.072	.008
<i>¬cárie</i>	.016	.064	.144	.576

- O denominador pode ser visto como uma constante de normalização α .

$$\begin{aligned}
 P(\text{Cárie} | \text{dordedente}) &= \alpha P(\text{Cárie}, \text{dordedente}) \\
 &= \alpha [P(\text{Cárie}, \text{dordedente}, \text{boticão}) + P(\text{Cárie}, \text{dordedente}, \neg \text{boticão})] \\
 &= \alpha [<0.108, 0.016> + <0.012, 0.064>] \\
 &= \alpha [<0.12, 0.08>] \\
 &= <0.6, 0.4>
 \end{aligned}$$

Redes Bayesianas

Cap 14

Seções 1 – 3

Outline


- Sintaxe
- Semântica
- Distribuições parametrizadas

Redes Bayesianas

- Estrutura de dados para representar as dependências entre variáveis e fornecer uma especificação concisa de *qualquer* distribuição de probabilidade conjunta total.
- Sintaxe:
 - um conjunto de nós, um para cada variável aleatória
 - grafo direcionado e acíclico (seta = "influência direta")
 - cada nó tem uma distribuição condicional $P(X_i | \text{Pais}(X_i))$ que quantifica o efeito dos pais sobre o nó
- No caso mais simples, a distribuição condicional é representada como uma *tabela de probabilidade condicional* (TPC) dada uma distribuição sobre X_i para cada combinação de valores dos pais.

Exemplo

- A topologia de uma rede representa relações de independência condicional :

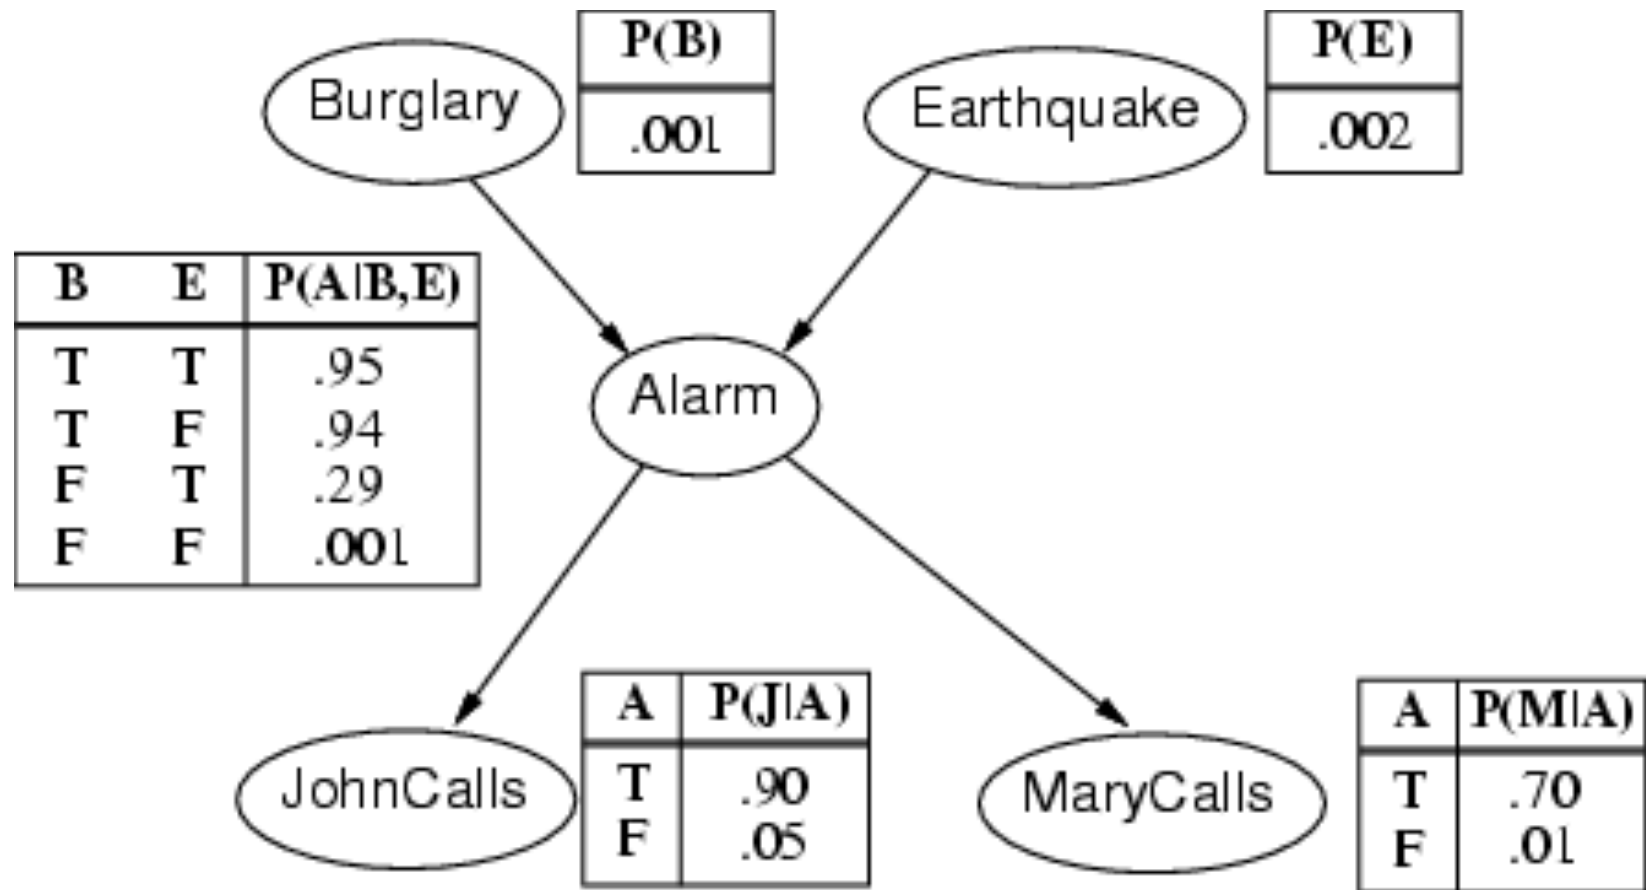


- *Clima* é independente de outras variáveis
- *Toothache* e *Catch* são condicionalmente independentes dado *Cavity*

Exemplo

- “ *I'm at work, neighbor John calls to say my alarm is ringing, but neighbor Mary doesn't call. Sometimes it's set off by minor earthquakes. Is there a burglar?* ”
- Variáveis: *Burglary, Earthquake, Alarm, JohnCalls, MaryCalls*
- A topologia da rede reflete conhecimento "causal":
 - Um roubo (*burglar*) pode ligar o alarme
 - Um terremoto (*earthquake*) pode ligar o alarme
 - O alarme faz Mary telefonar
 - O alarme faz John telefonar

Exemplo



Da topologia da rede

- Roubos e terremotos afetam diretamente a probabilidade do alarme tocar;
- Mas o fato de Joao e Maria telefonarem só depende do alarme;
- Desse modo, **a rede representa nossas suposições de que eles não percebem quaisquer roubos diretamente, não notam os terremotos e não verificam antes de ligar!**

As probabilidades...

- ... resumem um conjunto potencialmente infinito de circunstâncias (Maria ouve música alta, João liga qdo toca o telefone; umidade, falta de energia, etc podem interferir no alarme; Joao e maria não estão em casa, etc.
- **Preguiça e ignorância**

Tabelas de probabilidade condicional (TPC)

- Cada linha em uma TPC contém a probabilidade condicional de cada valor de nó para um **caso de condicionamento**;
 - um caso de condicionamento é apenas uma combinação possível de valores para os nós superiores
- Cada linha requer um número p para $X_i = \text{true}$ (prob. para $X_i = \text{false}$ é $1-p$)
- Um nó sem pais tem apenas uma linha: probabilidade a priori
- Em geral, uma tabela para uma var. booleana com k pais booleanos possui 2^k probabilidades
- Se cada var. não possuir mais do que k pais, a rede completa será $O(n \cdot 2^k)$, para n = número de nós.
 - I.e., cresce linearmente em n , vs. $O(2^n)$ da distribuição total


Semântica das RB

- Duas maneiras equivalentes:
 - **Semântica global** (ou numérica): entender as redes como uma representação da distribuição de probabilidade conjunta;
 - indica como construir uma rede
 - **Semântica local** (ou topológica): visualizá-las como uma codificação de uma coleção de declarações de independência condicional.
 - Indica como fazer inferências com uma rede.

Semântica Global


A semântica global (ou numérica) define a distribuição de probabilidade total como o produto das distribuições condicionais locais:

$$\mathbf{P}(X_1, \dots, X_n) = \prod_{i=1} \mathbf{P}(X_i | \text{Parents}(X_i))$$



Semântica Global


Se uma rede bayesiana for uma representação da distribuição conjunta, então ela poderá ser utilizada para responder qqr consulta efetuando-se o somatório de todas as entradas conjuntas relevantes



Semântica Global

A semântica global (ou numérica) define a distribuição de probabilidade total como o produto das distribuições condicionais locais:


$$\mathbf{P}(X_1, \dots, X_n) = \prod_{i=1} \mathbf{P}(X_i \mid \text{Parents}(X_i))$$




e.g., $\mathbf{P}(j \wedge m \wedge a \wedge \neg b \wedge \neg e)$
 $= \mathbf{P}(j \mid a) \mathbf{P}(m \mid a) \mathbf{P}(a \mid \neg b, \neg e) \mathbf{P}(\neg b) \mathbf{P}(\neg e)$
 $= 0.9 \times 0.7 \times 0.001 \times 0.999 \times 0.998$
 $= 0.00063$

Semântica local

- **Semântica local** (topológica):
cada nó é condicionalmente independente de seus não-descendentes, dados seus pais. Ex. **J** é independente de **B** e **E**




Semântica local



Um nó X é condicionalmente independente de seus não descendentes (ex. Z_{ij}) dados seus pais (U_i)

Semântica local



Um nó X é condicionalmente independente todos os outros dada a sua **cobertura de Markov**

Semântica local e global

- A partir dessas asserções sobre a independência condicional e das TPCs, a distribuição conjunta pode ser reconstruída;
 - desse modo a semântica numérica e topológica são equivalentes.

Construindo uma rede Bayesiana

- 1. Escolher uma ordem para as variáveis aleatórias X_1, \dots, X_n
- 2. Para $i = 1$ à n
 - adicione X_i à rede
 - selecione pais para X_1, \dots, X_{i-1} tais que

$$P(X_i | \text{Pais}(X_i)) = P(X_i | X_1, \dots, X_{i-1})$$

Esta escolha de pais garante a semântica global:

$$\begin{aligned} P(X_1, \dots, X_n) &= \prod_{i=1}^n P(X_i | X_1, \dots, X_{i-1}) \text{ (regra da cadeia)} \\ &= \prod_{i=1}^n P(X_i | \text{Pais}(X_i)) \text{ (por construção)} \end{aligned}$$

Ordem para as variáveis

- A ordem correta em que os nós devem ser adicionados consiste em adicionar primeiro as “causas de raiz”, depois as variáveis que elas influenciam e assim por diante, até chegarmos às folhas, que não tem nenhuma influência causal direta sobre as outras variáveis.
- E se escolhermos a ordem “errada”??

Exemplo

- Assumindo a ordem: M, J, A, B, E


MaryCalls

JohnCalls

$$P(J \mid M) = P(J)?$$

Exemplo

- Assumindo a ordem: M, J, A, B, E




$P(J \mid M) = P(J)$? **No**

$P(A \mid J, M) = P(A \mid J)$? $P(A \mid J, M) = P(A)$?

Exemplo

- Assumindo a ordem: M, J, A, B, E



$P(J \mid M) = P(J)$? **No**


$P(A \mid J, M) = P(A \mid J)$? $P(A \mid J, M) = P(A)$? **No**

$P(B \mid A, J, M) = P(B \mid A)$?

$P(B \mid A, J, M) = P(B)$?

Exemplo

- Assumindo a ordem: $M, J,$



$P(J \mid M) = P(J)$? **No**

$P(A \mid J, M) = P(A \mid J)$? $P(A \mid J, M) = P(A)$? **No**


$P(B \mid A, J, M) = P(B \mid A)$? **Yes**

$P(B \mid A, J, M) = P(B)$? **No**

$P(E \mid B, A, J, M) = P(E \mid A)$?

$P(E \mid B, A, J, M) = P(E \mid A, B)$?

Exemplo



$P(J \mid M) = P(J)$? No

$P(A \mid J, M) = P(A \mid J)$? $P(A \mid J, M) = P(A)$? No


$P(B \mid A, J, M) = P(B \mid A)$? Yes

$P(B \mid A, J, M) = P(B)$? No

$P(E \mid B, A, J, M) = P(E \mid A)$? No


$P(E \mid B, A, J, M) = P(E \mid A, B)$? Yes

Exemplo




- A rede resultante terá dois vínculos a mais que a rede original e exigirá outras probabilidades para serem especificadas
- Alguns dos vínculos apresentam relacionamentos tênues que exigem julgamentos de probabilidade difíceis e antinaturais (prob de *Terremoto*, dados *Roubo* e *Alarme*)
- (Em geral) é melhor pensar de *causas* para *efeitos* (modelo causal) e não do contrário (modelo de diagnóstico)

Exemplo



(a)



(b)

- Uma ordenação de nós ruim: *MarryCalls*, *JohnCalls*, *Earthquake*, *Burglary* e *Alarm*
- Entretanto, todas as três redes devem representar a mesma **distribuição conjunta**. As duas últimas só não expressam todas as independências condicionais

Representação eficiente de distribuições condicionais

- Ainda que o número de pais k seja reduzido, o preenchimento da TPC para um nó exige até $O(2^k)$ e muita experiência para decidir os casos condicionais.
 - Esse é o pior caso, em que os relacionamentos de pais e filhos é arbitrário
- Em muitos casos podemos utilizar um padrão (***distribuição canônica***) para obter a tabela.

Representação eficiente de distribuições condicionais

- ***Distribuição canônica:***

- ajustar a distribuição de probabilidades em cada nó a alguma forma padrão;
- nestes casos a tabela completa pode ser especificada nomeando-se o padrão e fornecendo-se alguns parâmetros.
- Exemplos:
 - nós determinísticos
 - relacionamentos lógicos ruidosos: *ou-ruidoso*

Representação eficiente: Distribuição canônica

- **Nós determinísticos:** tem seus valores especificados pelos valores de seus pais, sem qualquer incerteza:
 - $X = f(\text{Pais}(X))$ para alguma função f ;
 - funções booleanas:
 - Norte Americano \Leftrightarrow Canadense \vee US \vee Mexicano
 - relação numérica entre funções contínuas:
 - **pais afluentes/escoadouros filhos:** $\Delta \text{nível da água}$
 - $\Delta \text{nível da água} = \text{afluentes} - \text{escoadouros}$
 - *Valor mínimo de alguma função*

Representação eficiente: Distribuição canônica

- **Ou-ruidoso**

- $P(\neg \text{fever} \mid \text{cold}, \neg \text{flu}, \neg \text{malaria}) = 0.6$
- $P(\neg \text{fever} \mid \neg \text{cold}, \text{flu}, \neg \text{malaria}) = 0.2$
- $P(\neg \text{fever} \mid \neg \text{cold}, \neg \text{flu}, \text{malaria}) = 0.1$

<i>Cold</i>	<i>Flu</i>	<i>Malaria</i>	<i>P(Fever)</i>	<i>P(¬Fever)</i>
F	F	F	0.0	1.0
F	F	T	0.9	0.1
F	T	F	0.8	0.2
F	T	T	0.98	$0.02 = 0.2 \times 0.1$
T	F	F	0.4	0.6
T	F	T	0.94	$0.06 = 0.6 \times 0.1$
T	T	F	0.88	$0.12 = 0.6 \times 0.2$
T	T	T	0.988	$0.012 = 0.6 \times 0.2 \times 0.1$

Representação eficiente: Distribuição canônica

- **Ou-ruído** (em contraste com o ou proposicional)
 - Permite a incerteza sobre a habilidade de cada pai para fazer o filho ser verdadeiro - o relacionamento entre pai e filho pode ser inibido.
 - Todas as causas listadas
 - inibições independentes
 - Assim “febre é falsa sse todos os seus pais verdadeiros são inibidos, e a probabilidade de isso ocorrer é o produto das probabilidades de inibição de cada pai.

<i>Cold</i>	<i>Flu</i>	<i>Malaria</i>	$P(\text{Fever})$	$P(\neg \text{Fever})$
F	F	F	0.0	1.0
F	F	T	0.9	0.1
F	T	F	0.8	0.2
F	T	T	0.98	$0.02 = 0.2 \times 0.1$
T	F	F	0.4	0.6
T	F	T	0.94	$0.06 = 0.6 \times 0.1$
T	T	F	0.88	$0.12 = 0.6 \times 0.2$
T	T	T	0.988	$0.012 = 0.6 \times 0.2 \times 0.1$

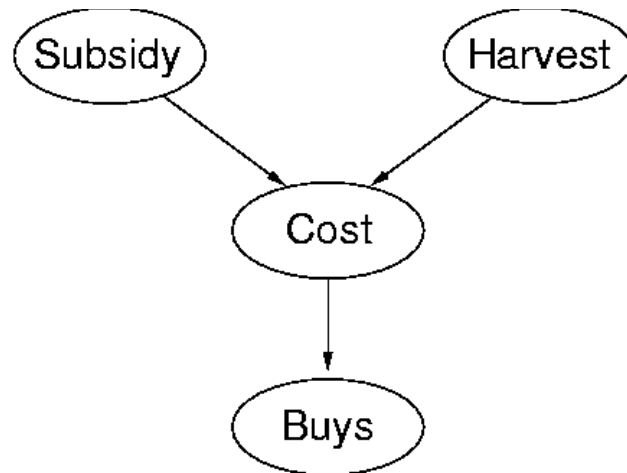
$$P(\neg \text{fever} | \text{cold}, \neg \text{flu}, \neg \text{malaria}) = 0.6$$

$$P(\neg \text{fever} | \neg \text{cold}, \text{flu}, \neg \text{malaria}) = 0.2$$

$$P(\neg \text{fever} | \neg \text{cold}, \neg \text{flu}, \text{malaria}) = 0.1$$


Redes de Bayes Híbridas

- Discretas: *Subsidy?* e *Buys?*




- Dois novos tipos de distr. condicionais:
 - **variável contínua, com pais contínuos e discretos (*Cost*)**
 - **Variável discreta com pais contínuos (*Buys?*)**

Redes de Bayes Híbridas




- Manipular variáveis contínuas:
 - **Discretização:** repartir os valores possíveis em um conjunto fixo de intervalos
 - **Definir funções de probabilidade padrão** especificadas por um número finito de parâmetros

variável contínua, com pais contínuos e discretos (**Cost**)




- Para custo: $P(\text{Custo}|\text{Colheita}, \text{Subsídio})$
 - O pai discreto (*Subsídio*) é manipulado por enumeração explícita:
 $P(\text{Custo}|\text{Colheita}, \text{subsídio})$ e $P(\text{Custo}|\text{Colheita}, \neg\text{subsídio})$
- Para *Colheita* especificamos como a distribuição sobre o custo **c** depende do valor contínuo **h** de colheita.
 - I.e., os parâmetros da distribuição de custo como função de **h**
 - em geral: **distribuição Gaussiana linear**

variável contínua, com pais contínuos e discretos (*Cost*)




- **distribuição gaussiana linear:** o filho (*Cost*) tem uma distribuição gaussiana cuja média varia linearmente com o valor do pai (*Harvest*), e cujo desvio padrão é fixo:

$$\begin{aligned} P(\text{Cost} = c | \text{Harvest} = h, \text{Subsidy?} = \text{true}) \\ &= N(a_t h + b_t, \sigma_t)(c) \\ &= \frac{1}{\sigma_t \sqrt{2\pi}} \exp \left(-\frac{1}{2} \left(\frac{c - (a_t h + b_t)}{\sigma_t} \right)^2 \right) \end{aligned}$$




- **distribuição gaussiana linear:** o filho (*Cost*) tem uma distribuição gaussiana cuja média varia linearmente com o valor do pai (*Harvest*), e cujo desvio padrão é fixo:

$$\begin{aligned} P(\text{Cost} = c | \text{Harvest} = h, \text{Subsidy?} = \text{true}) \\ &= N(a_t h + b_t, \sigma_t)(c) \\ &= \frac{1}{\sigma_t \sqrt{2\pi}} \exp \left(-\frac{1}{2} \left(\frac{c - (a_t h + b_t)}{\sigma_t} \right)^2 \right) \end{aligned}$$




- **distribuição gaussiana linear:** o filho (*Cost*) tem uma distribuição gaussiana cuja média varia linearmente com o valor do pai (*Harvest*), e cujo desvio padrão é fixo:

$$\begin{aligned} P(\text{Cost} = c | \text{Harvest} = h, \text{Subsidy?} = \text{true}) \\ &= N(a_t h + b_t, \sigma_t)(c) \\ &= \frac{1}{\sigma_t \sqrt{2\pi}} \exp \left(-\frac{1}{2} \left(\frac{c - (a_t h + b_t)}{\sigma_t} \right)^2 \right) \end{aligned}$$



$$\begin{aligned}
 P(\text{Cost} = c | \text{Harvest} = h, \text{Subsidy?} = \text{true}) \\
 &= N(a_t h + b_t, \sigma_t)(c) \\
 &= \frac{1}{\sigma_t \sqrt{2\pi}} \exp\left(-\frac{1}{2} \left(\frac{c - (a_t h + b_t)}{\sigma_t}\right)^2\right)
 \end{aligned}$$



A inclinação é negativa, pq o preço diminui à medida que a quantidade oferecida aumenta



Distribuição gaussiana condicional linear

- Uma rede que contém apenas variáveis contínuas com distribuições Gaussianas lineares tem uma distribuição conjunta que é uma **distribuição multivariada** sobre todas as variáveis.
 - superfície em mais de uma dimensão que tem um pico na média (em n dimensões) e decresce para todos os lados.
- Com variáveis discretas (se nenhuma destas é filha de uma var. contínua), a rede define uma **distribuição gaussiana condicional**
 - dada qqr. atribuição às var. discretas, a distribuição sobre as var. contínuas é uma **distribuição gaussiana multivariada**.

variáveis discretas com pais contínuos

- Ex. *Compras*:
 - Podemos supor que o cliente comprará se o preço for baixo e não comprará se for alto e que:
 - A probabilidade de compra varia suavemente em alguma região intermediária
 - A distribuição condicional é semelhante a uma função de limiar “suave” (*soft threshold*)
 - Distribuição **probit** é uma possibilidade...

v.discretas, pais contínuos





- Probabilidade de *Compra (buys)* dado *Custo (Cost)*: **limiar suave**
- Distribuição **Probit**:
 - integral da Gaussiana
 - limiar difícil, mas a sua posição precisa está sujeita a ruído gaussiano aleatório

$$\Phi(x) = \int_{-\infty}^x N(0, 1)(x) dx$$

$$P(\text{Buys?} = \text{true} | \text{Cost} = c) = \Phi((-c + \mu)/\sigma)$$

v.discretas, pais contínuos




- Probabilidade de *Compra (buys)* dado *Custo (Cost)*: **limiar suave**
 - O limiar do curto ocorre em torno de , a largura do limiar é a a prob. de compra diminui à medida que o custo aumenta.

$$\Phi(x) = \int_{-\infty}^x N(0, 1)(x)dx$$

$$P(Buys? = true \mid Cost = c) = \Phi((-c + \mu)/\sigma)$$

Por que Probit?

- Possui mais ou menos o formato desejado
- Pode ser visto como um degrau em que a posição é ruidosa



Resumo

- Redes Bayesianas são representações explícitas de independência condicional
- Topologia + TPCs = representações compactas de distribuições conjuntas totais
- Ferramentas poderosas para construir uma representação de um domínio que envolva incerteza.